

Pipeline de Analítica Predictiva para Detección Temprana de Riesgo de Deserción

Facultad de Sistemas | Jornada Nocturna

Autores:

Correal Martínez & Guzmán Rodríguez

Docente:

Doris Constanza Alvarado Mariño

Algoritmo:

Random Forest | n=100 | max_depth=6

Dataset:

1,000 estudiantes sintéticos — 24 variables

Fecha:

Mayo 25 de 2026

Nivel TRL:

TRL 2/3 — Validación con datos sintéticos

¿Qué problema resuelve este pipeline?

Contexto institucional y estructura del dataset sintético

Problema

El 12.05% de estudiantes nocturnos de la ETITC abandonan cada semestre.

Restricción

Sin acceso a microdatos individuales reales (Ley 1581/2012 — Habeas Data).

Solución

Dataset sintético de 1,000 estudiantes calibrado con 10 semestres de informes de Bienestar.


Arquitectura

3 CSV relacionales: Bienestar + Notas + Target unificados por id_estudiante (INNER JOIN).

Meta

Validar consistencia técnica del pipeline antes de recibir datos reales anonimizados.



Balance de clases (variable objetivo)



Archivo CSV	Tamaño	Tipo
bienestar_caracterizacion	7 col.	Socio-económica
adviser_teams_notas	19 col.	Rendimiento académico
registro_admisiones_target	2 col.	Variable objetivo
Unificada (post-merge)	26 col.	Entrada al modelo

Perfil socioeconómico simulado — Bienestar Universitario


Calibrado con los informes de los 10 semestres consecutivos (2021-I a 2025-II)




Rendimiento académico dinámico — Los tres cortes institucionales

Adviser V.11 × Microsoft Teams | Tendencia de degradación semestral

Distribución de notas definitivas por corte
(tendencia a la baja por fatiga laboral acumulada)




Asistencia vs. ausentismo por corte
(presión laboral → ausentismo crece en C3)




Validación de las Reglas de Negocio Programadas

Regla 2: penalización por ausentismo | Regla 3: choque cognitivo en ciencias básicas

Regla 2: Penalización de entregas
si trabaja=1 v conflicto_tiempo=1




Regla 3: Choque cognitivo
si brecha_bach > 3 ^ debilidad_mate = 1



Evaluación del Modelo — Matriz de Confusión

Conjunto de prueba: 200 estudiantes | Accuracy = 94.0%

Matriz de Confusión



148

Verdaderos Negativos

Persiste → predijo Persiste
Sin alerta. Correcto.

1

Falsos Positivos

Persiste → predijo Deserto
Falsa alarma.
Bienestar interviene sin necesidad.

11

Falsos Negativos ⚠

Deserto → predijo Persiste
ERROR CRÍTICO: alumno en riesgo no detectado.

40


Verdaderos Positivos

Deserto → predijo Deserto
Alerta correcta.
Intervención posible.


Curvas de Rendimiento del Clasificador

ROC-AUC = 0.996 | Un modelo aleatorio obtendría AUC = 0.500

Curva ROC — AUC = 0.996




Curva Precision-Recall (clave para clases desbalanceadas)



Métricas de Rendimiento — Classification Report


Evaluable sobre el 20% de datos reservados (200 muestras estratificadas)



Clase	Precision	Recall	F1-Score	Support
Persiste (0)	0.931	0.993	0.961	149
Deserto (1)	0.976	0.784	0.870	51

Top 12 Sensores Predictivos — Importancia de Variables

Gini Impurity promediada sobre 100 árboles | Azul = académica | Naranja = socioeconómica



HALLAZGO CLAVE

Las 5 variables más importantes explican el 60.4% del poder predictivo total.

#1 definitiva_c3

Peso: 0.1774

La nota final del último corte es el indicador más crítico.

#2 definitiva_c2

Peso: 0.1420

El corte 2 anticipa el resultado final con alta correlación.

#3 autoevaluacion_c3

Peso: 0.1247

Valor = 0.0 activa la Regla 4 de deserción tardía.

¿Qué aprendió el modelo? — Interpretación para Bienestar Universitario

Traducción de las métricas a acciones institucionales concretas

DOMINIO ACADÉMICO

Las 5 variables top son cortes académicos, no factores sociales.

La 'huella digital' (definitivas + autoevaluación) supera al perfil inicial de Bienestar como predictor. Esto valida la arquitectura Multi-CSV del proyecto.

EL ERROR CRÍTICO: 11 Falsos Negativos

El modelo falló en detectar 11 de los 51 desertores reales del conjunto de prueba.

Son alumnos que el sistema dejaría pasar sin intervención. Reducirlos requiere bajar el umbral de decisión (< 0.5) o usar `class_weight='balanced'`.

RECALL del 78.4% — ¿Es suficiente?

El modelo detecta 8 de cada 10 estudiantes en riesgo real.

En producción, si hay 100 desertores potenciales en un semestre, el modelo alertaría sobre ~78. Los 22 restantes requerirían un segundo modelo de alerta tardía.

PRECISION del 97.6% — Bajo ruido de falsas alarmas

Solo 1 estudiante recibió alerta incorrecta en las 200 muestras de prueba.

Bienestar podría intervenir sobre las alertas del modelo sin saturar su capacidad, ya que casi todas las alertas corresponden a riesgo real confirmado.

Conclusiones y Próximos Pasos

TRL 2/3 validado — Arquitectura consistente — Lista para datos reales

Arquitectura Multi-CSV validada El INNER JOIN de 3 fuentes CSV produce una matriz de 1,000 × 24 sin nulos, demostrado para n=1,000 sintéticos.	Paso 1: Ajuste de umbral Bajar el threshold de 0.5 a ~0.35 para priorizar Recall sobre Precisión y reducir los 11 FN.
Patrones estadísticos separables Accuracy=94.0% AUC=0.996 confirman que las reglas de negocio generan señales que el algoritmo puede aprender.	Paso 2: Comparar con XGBoost Entrenar XGBoost con los mismos datos y evaluar si mejora el F1-Score para la clase minoritaria.
Hipótesis central validada Las variables académicas dinámicas (cortes) tienen mayor peso predictivo que el perfil socioeconómico estático.	Paso 3: Validación cruzada k-fold Reemplazar el split 80/20 por k=5 folds para estimar varianza del modelo con más robustez.
Limitación metodológica (TRL 2/3) Las métricas altas se deben a que el modelo aprende las mismas reglas que generaron los datos sintéticos. Requiere validación con microdatos reales anonimizados.	Paso 4: Datos reales Acuerdo de confidencialidad con ETITC (Ley 1581/2012) para acceder a sábanas anonimizadas de Adviser V.11.